

# Primer Parcial

## Práctica 1: Repaso álgebra lineal

1.  $v^t u u^t v = (u^t v)^2$
2. Si  $x^t x = 0 \Rightarrow x = 0$
3.  $AB \neq BA$
4.  $C(A + B) = CA + CB$
5. Regla general multiplicación  $AB$ :  
$$\begin{pmatrix} a_1^t \\ a_2^t \\ a_3^t \end{pmatrix} B = \begin{pmatrix} a_1^t B \\ a_2^t B \\ a_3^t B \end{pmatrix}$$
$$A \begin{pmatrix} b_1 & b_2 & b_3 \end{pmatrix} = \begin{pmatrix} Ab_1 & Ab_2 & Ab_3 \end{pmatrix}$$
6.  $(AB)_{ij} = \text{fila}_i(A) * \text{col}_j(B)$
7.  $Ae_i = \text{col}_i(A)$
8.  $e_i^t A = \text{fila}_i(A)$
9.  $e_i^t A e_i = a_{ii}$
10. Producto de matrices triangulares (sup o inf) es triangular (sup o inf)
11.  $\dim(\text{Im}(A)) = \text{rango}(A)$  (cantidad de columnas linealmente independientes)
12. Teorema de la dimensión:  $A \in \mathbb{R}^{m \times n}$ ,  $\dim(\text{Nu}(A)) + \dim(\text{Im}(A)) = n$
13. Matriz estrictamente diagonal dominante:  $|a_{ii}| > \sum_{j \neq i} |a_{ij}|$ 
  - A es estrictamente diagonal dominante cuando lo es por **filas** ó por **columnas**
  - **Por filas**: para cada fila, el módulo del elemento de la diagonal es estrictamente mayor a la suma de los módulos de los elementos de la fila.
  - **Por columnas**: análogo para columnas.
14. Matriz inversa
  - A inversible es equivalente a:
    - $\text{rango}(A) = n$  (todas sus columnas son li)
    - $\det(A) \neq 0$
    - $\text{Nu}(A) = \{0\}$
    - $Ax = b$  tiene única solución
    - $A^t A$  es inversible
  - $AA^{-1} = A^{-1}A = I$
  - $(AB)^{-1} = B^{-1}A^{-1}$
  - $(A^t)^{-1} = (A^{-1})^t$
  - $(kA)^{-1} = k^{-1}A^{-1}$ ,  $k \in \mathbb{R}$
  - Sea  $A$  matriz triangular, es inversible si los elementos de la diagonal son distintos de cero.
  - La inversa de una matriz triangular superior es triangular superior, y viceversa
  - Si  $A$  es estrictamente diagonal dominante entonces es **inversible**
  - **NO VALE** que  $(A + B)^{-1} = A^{-1} + B^{-1}$
15. Matriz traspuesta
  - **SI VALE** que  $(A + B)^t = A^t + B^t$
  - $(AB)^t = B^t A^t$
16. Traza
  - $\text{tr}(A) = \sum_{i=1}^n a_{ii}$

- $\text{tr}(AB) = \text{tr}(BA)$
- $\text{tr}(A + B) = \text{tr}(A) + \text{tr}(B)$

#### 17. Determinante

- $\det(AB) = \det(A) \cdot \det(B)$
- $\det(I) = 1$
- $\det(A) = \det(A^t)$
- $\det(A^{-1}) = (\det(A))^{-1} \iff A$  es inversible
- $\det(A) = \prod_{i=1}^n a_{ii} \iff A$  es triangular
- Si  $A \in \mathbb{R}^{n \times n} \Rightarrow \det(kA) = k^n \det(A)$  – Chequear qué pasa si  $A$  no es cuadrada.
- $A \in \mathbb{R}^{2 \times 2} \Rightarrow A^{-1} = \frac{1}{\det(A)} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$

### Práctica 2: Eliminación Gaussiana, Factorización LU y Normas

1.  $\kappa_2(A) = \|A\|_2 \|A^{-1}\|_2$

#### 2. Normas vectoriales

- **Cauchy**  $|z^t x|^2 \leq \|z\|_2^2 \|x\|_2^2$
- **Desigualdad triangular**  $\|x + y\| \leq \|x\| + \|y\|$
- $\|u + v\|_2^2 = \|u\|_2^2 + \|v\|_2^2 + 2u^t v$
- $\|x\|_p = \sqrt[p]{|x_1|^p + |x_2|^p + \dots + |x_n|^p}$
- $\|x\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$
- $\|x\|_1 = \sum_{i=1}^n |x_i|$
- $\|x\|_\infty = \max_{i=1 \dots n} x_i$
- $\|x\|_2^2 = x^t x$
- $\|x\|_\infty \leq \|x\|_1$
- $\|x\|_1 \leq n \|x\|_\infty$
- $\|x\|_\infty \leq \|x\|_2$

#### 3. Normas Matriciales

- $\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$  (máxima suma de cada columna)
- $\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$  (máxima suma de cada fila)
- $\|A\|_2 = \max_{\|x\|_2=1} \|Ax\|_2$
- $\|A\|_F = \sqrt{\sum_{i=1}^n \sum_{j=1}^n a_{ij}^2} = \sqrt{\|c_1(A)\|_2^2 + \dots + \|c_n(A)\|_2^2}$  donde  $c_i$  es la columna  $i$  de  $A$
- $\|A\|_F = \|A^t\|_F$  (ya que la  $\|\cdot\|_F$  es la raíz de la suma de todos sus elementos al cuadrado)
- $\|I\| = 1$
- $\|Ax\| \leq \|A\| \cdot \|x\|$
- $\|AB\| \leq \|A\| \cdot \|B\| \iff A, B$  son matrices cuadradas
- $\|A\|_M \leq \|A\|_2 \leq n \|A\|_M$

#### 4. Factorización LU

- $L$  ("Lower") es triangular inferior **con unos en la diagonal**. Debajo de la diagonal tiene los multiplicadores usados para la triangulación en la eliminación gaussiana.
- $U$  ("Upper") es triangular superior, y es el resultado de la triangulación de  $A$  en la eliminación gaussiana.
- $A$  estrictamente diagonal dominante  $\Rightarrow$  tiene factorización LU
- Submatrices de  $A$  inversibles  $\Rightarrow$  tiene factorización LU
- $A$  inversible **no necesariamente** tiene factorización LU
- Si  $A$  inversible y tiene LU  $\Rightarrow$  la LU es única
- $M_k M_{k-1} \dots M_1 A = U$

- $M_1 = I - r_1 e_1^t$ , donde  $r_1 = \begin{pmatrix} 0 \\ m_{21} \\ m_{31} \\ m_{41} \end{pmatrix}$  y  $m_{ij} = \frac{a_{ij}}{a_{jj}}$

### Práctica 3: SDP y factorización de Cholesky

1. Matriz simétrica:  $A = A^t$
2. Matriz antisimétrica:  $A^t = -A$
3.  $A + A^t$  es una matriz simétrica
4.  $A - A^t$  es una matriz antisimétrica
5. Toda matriz puede escribirse como la suma entre una matriz simétrica y una antisimétrica
6. Definida positiva  $\iff x^t A x > 0 \forall x \in \mathbb{R}^n, x \neq 0$
7. Si  $A$  es simétrica definida positiva  $\Rightarrow A^t = A$  y  $A^t$  es definida positiva
8. Si  $A$  no es inversible,  $AA^t$  es simétrica semi-definida positiva, es decir que  $x^t AA^t x \geq 0 \forall x$
9. Si  $A$  es SDP entonces:
  - $A$  inversible
  - $a_{ii} > 0$
  - Toda submatriz de  $A$  es sdp y por lo tanto inversible
  - $A$  tiene factorización LU (por prop anterior)
  - La submatriz 2 a  $n$  (después del primer paso de triangulación de la eliminación gaussiana) es SDP
10.  $A \text{ sdp} \iff B^t A B \text{ sdp}$  con  $B$  inversible
11. Si tiene fact LU y es simétrica, si es toda positiva  $\Rightarrow$  tiene factorización de Cholesky
12. Si  $A$  es sdp, el elemento de módulo máximo de  $A$  está en la diagonal.
13. Si  $A$  es sdp  $\Rightarrow |x^t A y| \leq \sqrt{x^t A x} \sqrt{y^t A y}$
14. Si  $A$  es sdp  $\Rightarrow |a_{ij}|^2 \leq a_{ii} a_{jj}$
15. Factorización de Cholesky
  - $A$  tiene factorización de Cholesky  $\iff A$  es sdp
  - $A = LU = LDL^t = L\sqrt{D}\sqrt{D}L^t = \hat{L}\hat{L}^t$  donde  $D = L^{-1}U^t$  y  $\hat{l}_{ii} = l_{ii}\sqrt{d_{ii}} = \sqrt{u_{ii}}$
  - $D$  es diagonal, con elementos estrictamente positivos
  - $\hat{L}$  **no necesariamente** tiene "unos" en la diagonal, pero  $l_{ii} > 0$

### Práctica 4: Matrices ortogonales y factorización QR

1.  $u \perp v \iff u^t v = 0$
2.  $Q \in \mathbb{R}^{n \times n}$  ortogonal  $\iff QQ^t = Q^t Q = I \wedge Q^t = Q^{-1}$
3.  $\|Q\|_2 = 1$
4.  $\kappa_2(Q) = 1$
5.  $\|Qx\|_2 = \|x\|_2$
6. Producto de matrices ortogonales es ortogonal
7. Sus columnas (filas) son ortogonales entre sí y tienen norma 2 igual a 1, entonces forman un conjunto ortonormal
8.  $\det(Q) = 1$  ó  $-1$
9.  $Ax = b \Rightarrow Rx = Q^t b$ ,  $Q$  ortogonal y  $R$  triangular superior
10. Si  $Q$  es ortogonal y triangular, entonces  $Q$  es diagonal y además  $col_i(Q) = \pm e_i$
11. Si  $A$  es inversible, entonces tiene una única factorización  $QR$  posible, donde  $R$  triangular superior con  $r_{ii} > 0$

12.  $A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}$ ,  $x = \begin{pmatrix} a_{11} \\ a_{21} \end{pmatrix}$ ,  $y = \begin{pmatrix} \|x\|_2 \\ 0 \end{pmatrix}$

13. Matrices de rotación (Givens)

- $W = \begin{bmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{bmatrix}$
- Rotación hacia el eje x:  

$$W = \begin{bmatrix} \frac{x_1}{\|x\|_2} & \frac{x_2}{\|x\|_2} \\ -\frac{x_2}{\|x\|_2} & \frac{x_1}{\|x\|_2} \end{bmatrix}$$

14. Matrices de reflexión (Householder)

- $v = x + y$
- $u = \frac{x-y}{\|x-y\|_2}$
- $H = I - 2uu^t$
- $H$  es simétrica y ortogonal

## Segundo Parcial

### Propiedades generales

- $\|Ax\|_2^2 = (Ax)^t Ax$
- $a^2 - b^2 = (a - b)(a + b)$
- $x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$
- $\|QA\| = \|A\|$  para cualquier  $Q$  matriz ortogonal
- $\|(v, w)\| = \|v\|_2^2 + \|w\|_2^2$  concatenación de vectores
- **Pitágoras:**  $\|u + v\|_2^2 = \|u\|_2^2 + \|v\|_2^2 + 2u^t v$ . Si  $u \perp v \Rightarrow \|u + v\|_2^2 = \|u\|_2^2 + \|v\|_2^2$
- $A^t A$  es simétrica semidefinida positiva, tiene base ortonormal de autovectores reales y autovalores no negativos.
- Sea  $\{x_1, x_2 \dots x_n\}$  base, puedo escribir a cualquier vector como  $v = \alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_n x_n$  donde  $\alpha_i = x_i^t v$

### Práctica 5: Autovalores y Autovectores

1.  $x \neq 0$  autovector con autovalor  $\lambda$  de  $A \iff Ax = \lambda x$
2. **Radio espectral:**  $\rho(A) = \max\{|\lambda| : \lambda \text{ autovalor de } A\}$
3.  $\det(A - \lambda I) = 0$  por lo tanto no es inversible
4. **Polinomio característico:**  $P(\lambda) = \det(A - \lambda I)$ ,  $\lambda$  autovalor de  $A \iff \lambda$  es raíz de  $P(\lambda)$
5. Si  $v$  es autovector de  $A$ ,  $\alpha v$  también lo es.
6. Si  $\lambda$  es autovalor de  $A \Rightarrow \lambda - \alpha$  es autovalor de  $A - \alpha I$
7. Si  $\lambda$  es autovalor de  $A$ , entonces los autovalores de  $\alpha I - \beta A$  son  $\alpha + \beta \lambda$
8. Si  $Av = \lambda v \Rightarrow A^k v = \lambda^k v$
9. Un  $\lambda$  puede estar asociado a lo sumo a  $m$  autovectores l.i., donde  $m$  es la multiplicidad en el polinomio característico
10. Si  $A$  es *ortogonal*  $\implies$  todos sus autovalores son 1 o  $-1$
11. Si  $A$  es *definida positiva* o *semi definida positiva*, todos sus autovalores  $\lambda > 0$
12. Si  $A$  no es *inversible*  $\Rightarrow \lambda = 0$  es autovalor de  $A$
13. Si  $\lambda = 0$  no es autovalor de  $A \Rightarrow A$  es inversible
14. Si  $A$  es *inversible*, si  $\lambda \neq 0$  es autovalor  $\Rightarrow \lambda^{-1}$  es autovalor de  $A^{-1}$
15. Si  $\lambda^1, \lambda^2, \dots, \lambda^n$  son autovalores distintos, con autovectores asociados  $v^1, v^2, \dots, v^n$  entonces  $A$  tiene  $n$  autovalores distintos, entonces tiene base de autovectores son todos l.i. Si  $A$  es simétrica también son ortonormales
16. Si  $A$  es *triangular*  $\implies$  sus autovalores son los elementos de su diagonal
17. Si  $v$  es un autovector asociado a  $\lambda$  entonces  $\alpha v$  también es un autovector asociado a  $\alpha$
18.  $A$  y  $A^t$  tienen los mismos autovalores, por lo tanto si  $\lambda$  es autovalor de  $AA^t$  lo es de  $A^t A$
19. Si  $A$  es simétrica, todos sus autovalores son reales y existen sus autovectores con coeficientes reales, además tiene base ortonormal de autovectores.
20. **Matrices semejantes:**  $A$  y  $B$  son *semejantes* si existe una matriz  $P$  inversible tal que:  $A = P^{-1}BP$ . Si son semejantes, comparten autovalores.
21. Sea  $Q$  matriz ortogonal,  $\lambda$  es autovalor de  $A \iff \lambda$  es autovalor de  $Q^t A Q$

22. Si  $A$  tiene todos sus autovalores reales, existe  $Q$  ortogonal tal que  $Q^t A Q = T$  con  $T$  triangular superior. Si  $A$  es simétrica,  $T = D$  diagonal conteniendo sus autovalores.
23. Si  $A$  tiene base de autovectores es **diagonalizable**:  $\exists S$  inversible con sus autovectores como columnas y  $D$  con sus autovalores en la diagonal, se escribe como  $A = SDS^{-1}$
24. Si  $A$  es diagonalizable,  $tr(A) = \sum_i \lambda_i$  y  $det(A) = \prod_i \lambda_i$
25. **Método de potencia**  $A$  con base de autovectores y  $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$ , el autovalor principal se obtendrá a partir de un  $x^{(0)}$  cualquiera iterando  $x_{k+1} = \frac{Ax_k}{\|Ax_k\|}$
26. **Método de deflación**  $A' = A - \lambda_1 v_1 v_1^t$  donde  $v_1$  es el autovector asociado al máximo autovalor  $\lambda_1$ . A esta matriz se le vuelve a aplicar el método de la potencia para conseguir el segundo mayor autovalor.

## Práctica 6: Descomposición en Valores Singulares

**Idea.**  $A \in \mathbb{R}^{m \times n}$ ,  $r = rg(A)$ , existe descomposición  $A = U \Sigma V^t$  con  $U \in \mathbb{R}^{m \times m}$ ,  $\Sigma \in \mathbb{R}^{m \times n}$ ,  $V \in \mathbb{R}^{n \times n}$

1. **Valores singulares:**  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0 \in \Sigma$
2.  $\frac{A v_i}{\sigma_i} = u_i$ , si  $i = 1, \dots, r$
3.  $A v_i = 0$ , si  $i = r + 1, \dots, n$
4.  $A^t u_i = \sigma_i v_i$  si  $i = 1, \dots, r$
5.  $A^t u_i = 0$ , si  $i = r + 1, \dots, m$
6.  $A^t A v_i = \sigma_i^2 v_i$ , si  $i = 1, \dots, r$
7.  $A^t A v_i = \lambda_i v_i$  ya que  $\sigma_i^2 = \lambda_i$
8.  $A^t A v_i = 0$ , si  $i = r + 1, \dots, n$
9. Obtener descomposición en valores singulares:
  - $\sigma_i = \sqrt{\lambda_i}$  con  $\lambda_i$  autovector de  $A^t A$
  - Las columnas  $v_1, v_2, \dots, v_n$  son base ortonormal de autovectores de  $A^t A$ ,  $V$  ortogonal
  - Calcular  $U$  según 3 y completar el resto de las columnas con base ortonormal del  $Nu(A^t)$ , o usar que las columnas  $u_1, u_2, \dots, u_m$  son base ortonormal de autovectores de  $A A^t$ , con  $U$  ortogonal
10.  $A A^t = U \Sigma \Sigma^t U^t$
11.  $A^t A = V \Sigma \Sigma^t V^t$
12.  $\|A\|_2 = \sigma_1$  valor singular mas grande
13. Si  $A$  inversible, el número de condición basado en la norma 2:  $\kappa_2(A) = \frac{\sigma_1}{\sigma_n}$
14. Si  $A$  inversible, los valores singulares de  $A^{-1}$  son  $\frac{1}{\sigma_n} \geq \dots \geq \frac{1}{\sigma_1}$
15.  $\|A\|_F = \sqrt{(\sigma_1)^2 + \dots + (\sigma_r)^2}$
16. Si  $\Sigma \in \mathbb{R}^{n \times n} \Rightarrow \Sigma^t \Sigma = \Sigma \Sigma^t = \Sigma^2$
17.  $A \in \mathbb{R}^{n \times n}$  simétrica definida positiva  $\Rightarrow$  los autovalores de  $A$  coinciden con sus valores singulares.

## Práctica 7: Métodos iterativos

**Idea.** Aproximar  $Ax = b$ ,  $A \in \mathbb{R}^{n \times n}$ ,  $b \in \mathbb{R}^n$  reescribimos  $A = D - L - U$

1. Esquema de iteración:  $x^{(k)} = T x^{(k-1)} + c$  donde  $T \in \mathbb{R}^{n \times n}$ ,  $c \in \mathbb{R}^n$
2. **Jacobi:**
  - Solo puede ser aplicado a una matriz  $A$  tal que  $a_{ii} \neq 0$
  - Si  $A$  es estrictamente diagonal dominante  $\Rightarrow$  el método converge
  - $T = D^{-1}(L + U)$ ,  $c = D^{-1}b$

### 3. Gauss Seidel:

- Si  $A$  es estrictamente diagonal dominante  $\Rightarrow$  el método converge
  - $T = (D - L)^{-1}U$ ,  $c = (D - L)^{-1}b$
4.  $A$  es convergente si  $\lim_{k \rightarrow \infty} A^k = 0$
  5. Si  $\|T\| < 1$  o  $\rho(T) < 1$  el sistema converge
  6. Si  $\rho(A) < 1 \iff \lim_{k \rightarrow \infty} \|A^k\| = 0 \iff \lim_{k \rightarrow \infty} A^k x = 0 \forall x \in \mathbb{R}^n$
  7. Si  $\rho(A) < 1$  entonces  $I - A$  es inversible
  8. Si  $A$  es simétrica definida positiva,  $GS$  converge
  9. Si  $L \in \mathbb{R}^{m \times n}$  es estrictamente triangular superior (ceros en la diagonal) entonces  $L^n = \emptyset$  ya que al multiplicarla por si misma se anulan sus supradiagonales

## Práctica 8: Cuadrados mínimos lineales

**Idea.** Dado un conjunto de pares ordenados  $(x_i, y_i)$  para  $i = 1, \dots, m$  buscamos una función  $f(x)$  perteneciente a una familia  $\mathcal{F}$  que “mejor aproxime” a los datos.

1.  $Im(A) \oplus Nu(A^t) = \mathbb{R}^n$
2.  $Im(A)^\perp = Nu(A^t)$
3.  $Nu(A)^\perp = \{y \in \mathbb{R}^n | y \perp x, \forall x \in Nu(A)\}$
4. Si  $b \in \mathbb{R}^n \Rightarrow b = b^1 + b^2$  donde  $b^1 \in Im(A)$  y  $b^2 \in Nu(A^t)$
5. Todo  $y \in Im(A)$  puede escribirse como combinación lineal de las columnas de  $A$
6. CML :  $\min_{x \in \mathbb{R}^n} \|Ax - b\|_2^2$
7. **Ecuaciones normales:**  $A^t Ax = A^t b$  cualquier solución de ecuaciones normales es solución de cuadrados mínimos para  $Ax = b$
8.  $\|u + v\|_2^2 = \|u\|_2^2 + \|v\|_2^2 + 2u^t v$
9. Si  $u \perp v \Rightarrow \|u + v\|_2^2 = \|u\|_2^2 + \|v\|_2^2$
10.  $Ax^* = b \iff x - x^* \in Nu(A)$
11. Cuadrados mínimos siempre tiene solución. La solución es **única**  $\iff Nu(A) = Nu(A^t A) = \{0\}$  o sea si las columnas de  $A$  son linealmente independientes.
12. Si  $Nu(A^t A) = \{0\}$  entonces  $A^t A$  es inversible, por lo tanto  $x^* = (A^t A)^{-1} A^t b$
13.  $\|Ax\|_2^2 = 0 \Rightarrow Ax = 0$
14.  $A \in \mathbb{R}^{m \times n}$  :
  - $A^t A$  semidefinida positiva
  - Si  $m < n$   $A^t A$  no es definida positiva
  - Si  $m \geq n$   $A^t A$  definida positiva si y solo si  $A$  tiene rango máximo
15. Si  $s \in S$  y  $t \in S^\perp$ , entonces existe una única forma de escribir  $w = s + t$  para todo  $w \in \mathbb{R}^n$
16. Sea  $S \subseteq \mathbb{R}^m$  subespacio, sea  $s \in S$  la proyección ortogonal  $P$  de  $x$  sobre el subespacio  $S \Rightarrow Px = s$
17. Caso cuadrados mínimos  $Ax$  es la proyección ortogonal de  $b$  sobre la imagen de  $A$
18.  $Ax \in Im(A) \wedge (b - Ax^*) \in Im(A)^\perp$  donde  $x^*$  solución de cuadrados mínimos

## Práctica 9: Interpolación. Integración numérica

### Interpolación

**Idea.** Dado un conjunto de pares ordenados de valores  $(x_i, y_i)$  para  $i = 0, \dots, n$  buscamos un polinomio  $P(x)$  de grado a lo sumo  $n$  tal que interpole los datos:

$$P(x_i) = y_i \quad \forall i = 0, \dots, n$$

1. Dados  $(x_i, y_i)$  para  $i = 0, \dots, n$ , el **polinomio interpolante** de grado menor o igual a  $n$  *existe* y es *único*.

2. **Polinomio de Lagrange:**

$$P(x) = \sum_{k=0}^n f(x_k) L_{nk}(x) = \sum_{k=0}^n f(x_k) \prod_{j=0, j \neq k}^n \frac{(x - x_j)}{(x_k - x_j)}$$

3. **Fórmula del error:** Si  $x_0, \dots, x_n \in [a, b]$ ,  $f \in C^{n+1}([a, b])$  y  $\xi_x \in [a, b]$

$$f(x) = P(x) + \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{i=0}^n (x - x_i)$$

4. **Diferencias divididas:**

$$P(x) = f[x_0] + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1) + \dots + f[x_0, \dots, x_n](x - x_0) \dots (x - x_{n-1})$$

- **Orden 0:**  $f[x_i] = f(x_i)$
- **Orden 1:**  $f[x_i, x_{i+1}] = \frac{f[x_{i+1}] - f[x_i]}{x_{i+1} - x_i}$
- **Orden  $k$ :**  $f[x_i, x_{i+1}, \dots, x_{i+k}] = \frac{f[x_{i+1}, \dots, x_{i+k}] - f[x_i, \dots, x_{i+k-1}]}{x_{i+k} - x_i}$

### Integración

**Idea.** Aproximar la integral  $\int_a^b f(x) dx \approx \sum_{i=0}^n a_i f(x_i)$

1. **Regla del trapecio:** Usando polinomio interpolador de grado 1 sobre  $a, b$

$$\int_a^b f(x) dx = \frac{h}{2} [f(x_1) + f(x_0)] - \frac{h^3}{12} f''(\xi) \quad h = x_1 - x_0$$

2. **Regla de Simpson:** Usando polinomio interpolador de grado 2 sobre  $a, \frac{a+b}{2}, b$

$$\int_a^b f(x) dx = \frac{(x_2 - x_0)}{6} [f(x_0) + 4f(x_1) + f(x_2)] - \frac{h^5}{90} f^{(4)}(\mu) \quad h = x_1 - x_0 \text{ y } \mu \in (a, b)$$

3. **Regla compuesta:** Sumar las distintas aproximaciones de las integrales en los distintos intervalos, aprovechando el hecho que  $\int_a^b f(x) dx = \sum_{i=0}^{n-1} (\int_{x_i}^{x_{i+1}} f(x) dx)$

(a) **Regla compuesta de trapecios:** Dividir  $[a, b]$  en  $n$  intervalos de longitud  $h = \frac{b-a}{n}$

$$\int_a^b f(x) dx \approx \frac{h}{2} \left( f(x_0) + 2 \sum_{i=1}^{n-1} f(x_i) + f(x_n) \right)$$

$$Error = -\frac{b-a}{12} h^2 f''(\mu) \quad \mu \in (a, b)$$

(b) **Regla compuesta de Simpson:**